

面向工业过程控制的 World Model： 预测、策略优化与 NeoRL Simulator 验证

PAI Industrial World Model Assessment

2026 年 8 月 15 日

摘要

本文围绕工业历史轨迹上的 World Model 学习、基于模型的策略优化以及 NeoRL simulator 长期控制评价展开。报告严格区分 dynamics validation 与 simulator reward：前者用于选择 World Model，后者仅用于策略优化和最终控制评价。正文比较五类 World Model、三种 model-based planning 方法与带 behavior KL 的 MB-PPO，并在最终未使用种子上验证选定系统。

核心结果。 M100 由 GRU+CEM 获得最佳最终控制结果；M1000 与 M10000 由 Transformer-2L+MPPI 胜出。三个最终系统在 seeds 100–109 上相对 BC 的 win rate 均为 100%。实验同时表明，one-step prediction、recursive rollout 与 downstream control utility 并不完全等价。

目录

1	Introduction / Task Overview	3
2	Problem Formulation and Data	3
2.1	State, action and transition	3
2.2	Reward and evaluation roles	4
2.3	Original Behavior reference	4
3	World Model Design	4
3.1	Compared architectures	4
3.2	Validation metrics and selection	5
4	World Model Experiments	5
4.1	Architecture $\times$ Data Scale	5
4.2	One-step and multi-step prediction	6
4.3	Transformer depth ablation	8
5	World-Model-Based Strategy Optimization	8
5.1	Model-Based Planning	8
5.2	Model-Based Reinforcement Learning	8
6	NeoRL Strategy Evaluation	9
6.1	Strategy comparison across data scales	9
6.2	World Model $\times$ Strategy controlled ablation	10
6.3	Final simulator evaluation	11
7	Discussion: 实验发现与思考	12
7.1	One-step accuracy is not sufficient	12
7.2	Prediction accuracy and downstream control utility are not identical	13
7.3	Weak World Models can be exploited by optimizers	13
7.4	More data does not guarantee monotonically better downstream control	13
7.5	Architecture and dataset scale interact	13
8	Industrial Applications and Deployment Considerations	13
8.1	Potential industrial applications	13
8.2	Deployment risks and safeguards	14
9	Future Research Directions	14
10	Conclusion and Task Coverage	14

1 Introduction / Task Overview

工业过程通常具有长时滞、变量耦合和直接试错成本高等特点。本文从已有工业轨迹出发，学习一个可递归预测未来状态的 World Model，再利用该模型在真实 simulator 交互之前进行动作序列优化或策略学习，最后在 NeoRL Industrial Benchmark 环境中评价 1000 步累计奖励。整体技术路线如figure 1所示。

本报告严格覆盖三项任务。Task 1 研究历史状态与动作到下一状态的预测，并同时评价单步准确率与多步误差累积；Task 2 研究两类基于 World Model 的策略优化，即 CEM、iCEM 和 MPPI 组成的 Model-Based Planning，以及带 behavior KL 约束的 MB-PPO；Task 3 将基础策略和优化策略部署到 NeoRL simulator，以 episode cumulative reward 作为主要控制指标。最后，报告单独讨论实验发现、智能制造应用与真实工业部署风险。




图 1: Overall framework. 历史轨迹首先用于学习下一帧 dynamics；World Model 只根据 validation prediction metrics 选择并冻结。冻结模型随后服务于 Model-Based Planning 或 MB-PPO，策略最终在 NeoRL simulator 中评价。Simulator reward 不会反向参与 World Model 选择。

该流程的核心控制变量是把“模型预测是否可信”与“策略回报是否更高”分开回答。前者只依赖统一 validation；后者在模型和策略配置冻结后才使用 simulator。这样既能公平比较架构，也能观察预测性能与控制效用是否一致。

2 Problem Formulation and Data

2.1 State, action and transition

NeoRL Industrial Benchmark 中的观测为 180 维向量，可重排为 30 个历史帧，每帧包含 6 个物理变量：setpoint、velocity、gain、shift、fatigue 和 consumption。动作 $a_t \in [-1, 1]^3$ 是三维连续控制量。令单帧为 $x_t \in \mathbb{R}^6$ ，历史窗口为 $x_{t-29:t}$ ，World Model 学习

$$(x_{t-29:t}, a_t) \mapsto \hat{x}_{t+1}. \quad (1)$$

预测下一帧后，将 $\hat{x}_{t+1}$ 放入窗口最前端并移除最旧帧，得到下一次递归预测所需的 180 维状态。这个滑动窗口使所有架构具有一致输入输出： $[B, 30, 6]$ history 与 $[B, 3]$ action 映射到 $[B, 6]$ next frame。

2.2 Reward and evaluation roles

NeoRL 的 classic industrial reward 为

$$r_{t+1} = - (3 \text{ fatigue}_{t+1} + \text{consumption}_{t+1}) . \quad (2)$$

因此，降低设备疲劳和资源消耗会使 reward 变得更高（更不负）。本文报告 1000 步 episode cumulative reward。需要强调的是，simulator reward 只用于策略优化与最终控制评价，绝不参与 World Model checkpoint 或架构选择。

2.3 Original Behavior reference

原始行为数据参考值 (Original Behavior) 按如下方式定义：NeoRL 数据集中的历史轨迹由原始行为策略采集。由于公开数据未提供可直接重新部署该采集策略的策略权重，本文统计数据集中已有轨迹的累计奖励作为原始行为水平参考；BC 及世界模型优化策略则统一部署到 NeoRL simulator 中评估。因此 Original Behavior 用于描述原始数据行为水平，不与在线策略做严格的同 seed 配对统计。该区分也符合 NeoRL 强调数据分布、行为策略和部署验证应被谨慎区分的初衷 [1]。

三个数据规模 M100、M1000 与 M10000 分别提供不同数量级的历史轨迹。跨规模比较不以 raw epoch 数判断训练充分性，因为不同规模的一轮训练对应不同样本数量；报告只比较统一 common-validation 上的最终预测指标。

3 World Model Design

3.1 Compared architectures

本文比较五类正式架构。MLP 把完整历史窗口展平后进行静态非线性映射；GRU 和 LSTM 通过递归隐状态提取时间依赖，其中 GRU 使用较简化的门控结构，LSTM 使用显式记忆单元；Transformer-2L 和 Transformer-4L 通过 self-attention 直接建模 30 帧之间的依赖 [2]。Transformer 深度实验只改变层数 2 到 4， d_{model} 、head 数、FFN 宽度和 dropout 保持不变。

表 1: World Model architectures. 参数量不随数据规模改变。

Architecture	Temporal modeling	Main configuration	Parameters
MLP	无显式时序递归	2×256 MLP, dropout 0.1	114,438
GRU	门控递归状态	2 层, hidden 128, action branch 64	177,030
LSTM	带记忆单元的递归状态	2 层, hidden 128, action branch 64	227,462
Transformer-2L	自注意力历史编码	$d = 64$, 4 heads, FFN 128, 2 层	91,142
Transformer-4L	自注意力历史编码	$d = 64$, 4 heads, FFN 128, 4 层	158,086

所有模型共享数据划分、normalization、optimizer、trainer、checkpoint 规则和 evaluation protocol。不同架构的参数量约为 9 万至 23 万，规模足够轻量，便于突出时序归纳偏置而不是单纯扩大容量。

3.2 Validation metrics and selection

NRMSE 使用固定 common-validation 目标标准差归一化，使不同架构和数据规模可以在同一口径下比较。评价包括 one-step NRMSE，以及使用真实记录动作但递归更新预测状态的 H1、H5、H10、H20 和 H50 NRMSE。Per-variable error 用于判断某个整体指标是否被特定物理变量主导。

模型选择只使用 validation dynamics：

1. 找到该数据规模下最低的 one-step NRMSE；
2. 保留满足 $\text{one-step} \leq 1.10 \times \text{best one-step}$ 的候选；
3. 在候选中最小化 $\text{mean}(\text{H5}, \text{H10}, \text{H20})$ ；
4. H50 仅作为长期 rollout 稳定性诊断。

这个规则先排除单步明显不合格的模型，再选择短中期递归预测最稳定者。任何 CEM、iCEM、MPPI 或 MB-PPO simulator reward 都不进入上述流程。

4 World Model Experiments

4.1 Architecture $\times$ Data Scale

正式比较包含 5 种架构与 3 个数据规模，共 15 组 World Model。Figure 2 用两个 annotated heatmap 分别回答单步与多步问题；每个单元格都来自同一 common-validation protocol，橙色边框表示最终 validation 选择。




图 2: Architecture and dataset scale jointly shape dynamics accuracy. a, one-step NRMSE。b, mean NRMSE at H5/H10/H20。数值越低越好，橙色边框表示 validation-only 规则选出的模型。M100 偏好 GRU；M1000 和 M10000 偏好 Transformer-2L。两张 heatmap 的排序并不完全一致，说明单步指标不能替代递归评价。

M100 中，GRU 在合格 one-step 候选里取得最低的短中期综合误差；M1000 与 M10000 则由 Transformer-2L 胜出。该结果不支持“某一架构永远最好”，而是说明时序归纳偏置与数据规模存在

交互。尤其是 M10000 中 MLP 并未因数据更多而自动获得更好结果，提示数据覆盖、优化预算和架构表达能力需要共同考虑。

表 2: Validation-only protocol selected World Models. H50 仅用于长期稳定性诊断。

Dataset	Architecture	Epoch	One-step	H5	H10	H20	H50
M100	GRU	35	0.180	0.223	0.273	0.374	0.649
M1000	Transformer-2L	20	0.183	0.243	0.305	0.405	0.774
M10000	Transformer-2L	4	0.205	0.258	0.298	0.293	0.510

4.2 One-step and multi-step prediction

One-step 只评价在真实历史状态条件下预测下一帧；实际规划会把预测值重新输入模型，因此误差会改变后续输入分布。Figure 3 固定 M1000 并展示五个正式 architecture checkpoint 在五个真实评价 horizon 上的结果，不做插值或平滑。




图 3: Recursive prediction error accumulation at M1000. 五个 marker 对应 H1、H5、H10、H20 和 H50 的真实评价点，连接线只辅助阅读。尽管 H1 均接近 0.2，不同架构在 H20–H50 明显分离；Transformer-2L 在 H5–H20 综合最好，而 Transformer-4L 的 H50 更低。

Per-variable 结果进一步说明 overall NRMSE 并不等同于每个工业变量都同样准确。Setpoint 在该 benchmark 中较稳定，而 velocity、shift、fatigue 和 consumption 的误差演化不同。Table 3 列出 M1000 Transformer-2L 的代表性变量级结果。

表 3: M1000 Transformer-2L 的 per-variable NRMSE。变量的误差积累速度明显不同。

Variable	One-step	H20	H50
Setpoint	0.000	0.000	0.000
Velocity	0.029	0.310	0.704
Gain	0.018	0.292	0.012
Shift	0.036	0.670	1.498
Fatigue	0.378	0.432	0.510
Consumption	0.234	0.406	0.773

Figure 4提供一条直观轨迹。为避免选择最好看的样本，先在 101 个确定性 validation 起点上计算 H50 误差，再选择最接近中位误差的起点；动作来自记录轨迹，只有状态递归使用模型预测。




图 4: Representative H50 recursive rollout. a-c, velocity、fatigue 与 consumption 的 ground truth 和 prediction。该轨迹按预先规定的中位误差规则选择，不代表最好或最差情况。短期趋势可以跟随真实状态，但变量级偏差会以不同方式累积；总体结论仍应以全体 validation 起点的 NRMSE 为准。

4.3 Transformer depth ablation

表 4: Transformer depth ablation. 单元格为 one-step / mean(H5,H10,H20); 差值为 4L 减 2L, 负值更优。

Scale	Transformer-2L	Transformer-4L	Difference
M100	0.179 / 0.470	0.182 / 0.425	+0.003 / -0.044
M1000	0.183 / 0.318	0.183 / 0.338	+0.000 / +0.020
M10000	0.205 / 0.283	0.188 / 0.295	-0.017 / +0.012

M100 中 4L 改善了多步综合误差但单步略差; M1000 中 4L 的 H50 更低, 但 H5-H20 综合反而更高; M10000 中 4L 单步更好, 却在 H20 与综合指标上落后 2L。由此不能得到“层数增加会随数据规模稳定增强”的结论, 也没有证据支持继续扩大到 6L。这里的重点是严格控制变量后的深度效应, 而不是把不同训练预算或旧结果混入比较。

5 World-Model-Based Strategy Optimization

5.1 Model-Based Planning

Model-Based Planning 在每个 simulator step 利用冻结 World Model 评估候选动作序列, 只执行最前面的动作, 然后根据新观测重新规划。

- **CEM**: 从参数化动作分布采样, 保留高回报 elite 序列, 并迭代更新均值和方差。它是一种不依赖梯度的轨迹优化方法。
- **iCEM**: 在 CEM 基础上加入 temporal colored noise、elite reuse、previous-solution shift 和 population decay 等机制, 以更少样本复用过去规划信息 [3]。
- **MPPI**: 基于路径积分和 importance weighting, 对大量带噪动作序列按预测 cost 赋权, 再更新控制序列 [4]。通俗地说, 它不是只保留少数 elite, 而是让更优样本获得更高权重。

三种方法均使用 $H=10$ 作为主 horizon, 并遵守 $[-1, 1]^3$ 动作约束。World Model 全程冻结, 规划结果不能反向修改模型。

5.2 Model-Based Reinforcement Learning

MB-PPO 在冻结 World Model 中生成 imagined rollout, 再用 PPO 的 clipped surrogate objective 更新 actor 和 value network[5]。与每一步都在线搜索的 planner 不同, MB-PPO 把模型中的优化结果压缩到一个可快速推理的 policy 中。

Behavior KL 约束度量当前 policy 与 BC 所代表的离线行为分布之间的偏离, 并把该偏离加入训练目标。其通俗含义是: 即使 World Model 认为某个数据分布外动作非常有利, policy 也不能毫无代价地远离历史行为。Figure 5 使用相同 M1000 GRU World Model、初始化、rollout 和 PPO 协议, 只改变是否加入 behavior KL。




图 5: Behavior-KL ablation for MB-PPO. a, 相同五个 development seeds 上的 simulator return; 空心点为单 seed, 实心点及误差条为 $\text{mean} \pm \text{population SD}$. b, 训练期间相对 BC 的 behavior KL。去除 KL 后 policy divergence 扩大, 平均 return 由约 -2.85×10^5 降至 -8.84×10^5 。该消融支持 behavior constraint 能抑制当前设置中的 model exploitation, 但不确定最佳 KL 系数。

6 NeoRL Strategy Evaluation

6.1 Strategy comparison across data scales

每个数据规模固定由 dynamics validation 选择出的同一个 World Model, 再比较 CEM、iCEM、MPPI 与 MB-PPO。所有方法使用相同 development seeds 42–46、相同 1000 步 episode 和相同 reward definition。因此, figure 6 and table 5 中的差异主要来自 strategy 与固定 World Model 之间的交互, 而不是更换模型或 seed。




图 6: Development strategy comparison across data scales. a–c, M100、M1000 和 M10000。空心点为 seeds 42–46，实心点及误差条为 mean $\pm$ population SD。M100 iCEM 明显超出主轴范围，因此在 inset 中保留全部五个 seed。CEM 在 M100 最高；MPPI 在 M1000 和 M10000 最高。

表 5: Development strategy matrix (seeds 42–46). 数值为 episode cumulative reward 的 mean $\pm$ population SD，越高越好。

Dataset	CEM	iCEM	MPPI	MB-PPO
M100	-274,238 $\pm$ 588	-2,646,910 $\pm$ 4,581	-348,211 $\pm$ 5,687	-281,009 $\pm$ 131
M1000	-267,826 $\pm$ 407	-334,597 $\pm$ 4,503	-221,072 $\pm$ 1,475	-285,326 $\pm$ 158
M10000	-269,218 $\pm$ 411	-321,264 $\pm$ 36,310	-223,774 $\pm$ 578	-285,217 $\pm$ 283

M100 上的 iCEM 和 MPPI 均明显落后，尤其 iCEM 出现一致的极低真实回报；相同算法通过了已知 dynamics 和 cost 上的 deterministic optimization test，因此这里更合理的解释是弱 World Model 与 optimizer 之间发生 model exploitation，而不是直接断言算法不适合 Industrial Benchmark。M1000 和 M10000 中 MPPI 的提升说明 World Model 质量是重要瓶颈。

6.2 World Model $\times$ Strategy controlled ablation

M1000 进一步完成两组控制变量实验：第一组固定 MPPI 配置，仅改变五种 World Model；第二组固定 MB-PPO 训练协议，仅改变 World Model。该实验研究 dynamics prediction ranking 与 downstream control ranking 是否完全一致，不用于反向修改 validation-only 模型选择。




图 7: World Model architecture affects planning and learned policies differently. a, 固定 MPPI 时五种 World Model 的 development return。b, 固定 MB-PPO protocol 时的结果。每组 $n = 5$ seeds, 点和误差条分别表示 individual seed 与 $\text{mean} \pm \text{population SD}$ 。MPPI 在 Transformer-4L 上最高, 而 MB-PPO 在 LSTM 上最高; dynamics validation 最优仍为 Transformer-2L。

6.3 Final simulator evaluation

所有模型、strategy 和设置冻结后, seeds 100–109 才首次用于最终评价。最终系统按 development 结果确定: M100 采用 GRU+CEM, M1000 与 M10000 采用 Transformer-2L+MPPI。Figure 8 and table 6 同时展示原始行为数据参考值、BC 与三个最终系统。




图 8: Final NeoRL simulator results on untouched seeds. Original Behavior 以灰色 box 表示 NeoRL 数据集 1000 条已有轨迹的累计奖励分布, 属于 unpaired dataset-trajectory reference。其余方法均部署到 NeoRL simulator; 空心点为 seeds 100–109, 实心点及误差条为 mean $\pm$ population SD。三个最终系统在十个 seed 上均优于 BC。

表 6: Final NeoRL evaluation. Online systems use untouched seeds 100–109. Original Behavior 来自数据集已有轨迹, 不是同 seed 在线部署。

Method/System	Evaluation source	Episode return	Δ vs BC	Win rate
原始行为数据参考值 (Original Behavior)	NeoRL dataset trajectories	$-282,885 \pm 1,197$	–	–
BC	NeoRL simulator	$-288,411 \pm 267$	0	–
M100: GRU + CEM	NeoRL simulator	$-274,181 \pm 396$	+14,229	100%
M1000: Transformer-2L + MPPI	NeoRL simulator	$-220,129 \pm 1,699$	+68,282	100%
M10000: Transformer-2L + MPPI	NeoRL simulator	$-223,876 \pm 1,033$	+64,535	100%

最终 M100、M1000 和 M10000 系统相对 BC 的平均提升分别为 14,229、68,282 和 64,535, win rate 均为 100%。这直接回答了 Task 3: 在当前 NeoRL Industrial Benchmark 设置中, 经过严格模型选择和策略冻结的 World-Model-based optimization 能够提高长期 cumulative reward。

7 Discussion: 实验发现与思考

7.1 One-step accuracy is not sufficient

One-step 输入始终来自真实历史, 而 planning 和 imagined rollout 会递归使用模型自己的预测。实验中多个 M1000 模型的 one-step NRMSE 非常接近, 但 H20 和 H50 差距显著; 单步最准确

的 checkpoint 也不必然具有最低 H5-H20 综合误差。因此，面向控制的 World Model 至少应联合报告 one-step 与 multi-step dynamics，而不能只以 one-step loss 决定部署。

7.2 Prediction accuracy and downstream control utility are not identical

M1000 控制变量实验中，dynamics validation 选择 Transformer-2L；MPPI 在 Transformer-4L 上取得更高 development return；MB-PPO 则在 LSTM 上更好。这说明通用 prediction error 与 downstream decision utility 可能并不完全一致，而且 online planning 与 learned policy 可能对不同类型的模型误差具有不同敏感性。不过，这只是当前五种架构、两类策略和一个数据规模上的实验观察，不能上升为普遍定律，也不应使用 simulator reward 反向修改 World Model 选择。

7.3 Weak World Models can be exploited by optimizers

M100 结果提供了最直接证据：更复杂或采样更积极的 optimizer 并不保证更可靠。Planner 可能发现 World Model 认为高收益、但真实 simulator 表现很差的动作区域；当训练数据覆盖不足时，这些动作往往位于模型不可信区域。因而 model-based control 需要关注“预测是否来自有数据支持的区域”，而不只是 optimistic predicted return。

7.4 More data does not guarantee monotonically better downstream control

从 M100 到 M1000，最终 return 显著提高；从 M1000 到 M10000 则没有继续单调提高，M1000 + MPPI 的最终平均 return 反而略高。可能原因包括数据覆盖而非数量本身、选定架构的 bias、不同规模下的训练步数结构，以及 planner 对局部误差的敏感性。现有实验能确认“更多数据不自动等于更高控制回报”，但不能把差异唯一归因于某一个因素。

7.5 Architecture and dataset scale interact

M100 中 GRU 更有优势，说明递归归纳偏置在较小数据下有效；M1000 和 M10000 中轻量 Transformer-2L 更强，显示 attention 在更大覆盖下能够提取有用历史依赖；Transformer-4L 没有稳定获得进一步收益。架构选择因此应与可用数据规模、rollout horizon 和部署策略共同评价，而不是预设 Transformer 或循环网络必然获胜。

8 Industrial Applications and Deployment Considerations

8.1 Potential industrial applications

World Model 能够在不直接扰动设备的情况下回答“如果改变控制量，未来状态可能如何演化”。潜在用途包括工艺参数优化、能耗与设备疲劳联合控制、future-state prediction、what-if control simulation、数字孪生、控制策略预验证、异常工况决策辅助，以及生产目标与设备状态的联合优化。对于复杂生产线，它还可以作为 operator 的决策支持工具，在执行动作前展示多种候选方案的预测后果。

8.2 Deployment risks and safeguards

真实工业数据比 benchmark 更复杂。Sensor noise、missing measurement、异常值和时间同步误差会直接污染 30 帧历史窗口；equipment aging、maintenance、生产配方和工况变化会造成 dynamics drift；停机、故障与极端负载往往在 offline data 中极少出现，使模型在最重要的安全区域反而最不确定。部署前必须显式评估 offline data coverage 和 out-of-distribution (OOD) operating conditions，而不能假设训练集大小足以代表所有未来状态。

控制层还必须处理 hard safety constraints、actuator rate/position limits、多目标权衡和 operator intervention。例如，疲劳与能耗的 reward 并不能自动表达产品质量、产量、排放和设备安全的全部要求。实际系统应把这些要求编码为不可违反的约束，而不是只依赖软 reward。Failure detection、fallback controller 和人工接管路径需要与学习策略同时设计。

本项目观察到的 model exploitation 尤其重要：实际部署不能允许 optimizer 无约束搜索 World Model 的高收益区域。更安全的方案应联合 model uncertainty、ensemble disagreement、OOD detection、可信动作区域、conservative objective 和安全过滤器。当不确定性超阈值时，系统应回退到经验证的 BC、传统控制器或人工操作。部署流程宜先经历离线回放、shadow testing、受限工况试运行和逐级放权，并持续监控 prediction residual、动作分布、reward decomposition 与安全事件。

模型更新同样需要治理。Continuous monitoring 应识别 dynamics drift；模型更新或 online adaptation 必须保留版本、数据窗口、验证记录和可回滚能力。对关键工业场景，还需考虑网络与算力故障、推理超时、传感器冗余、审计日志和责任边界。World Model 的价值不是替代所有传统控制，而是在明确安全边界内增强预测、搜索和预验证能力。

9 Future Research Directions

World Model 方面，可探索 probabilistic 或 ensemble dynamics、uncertainty-aware World Model、latent World Model、State Space Model/Mamba、recurrent-attention hybrid、decision-aware model training/selection，以及 multiple training seeds 下的鲁棒性。策略方面，可研究 uncertainty-aware MPC、conservative planning、constrained model-based RL、更先进的 model-based/offline RL、其他 trajectory optimization 方法、safety-aware policy optimization 和受控 online adaptation。这些方向用于解决不确定性、可信区域和分布漂移问题，不在本次简要考核中继续扩展实验。

10 Conclusion and Task Coverage

本次考核建立了从工业历史轨迹到 World Model、再到模型驱动策略优化和 NeoRL simulator 验证的完整链路。Task 1 通过五架构、三数据规模的统一 common-validation 比较，明确回答了单步预测与多步误差累积；Task 2 完成 CEM、iCEM、MPPI 和 MB-PPO 两类策略优化，并通过 behavior KL 消融观察到行为约束对抑制 model exploitation 的重要性；Task 3 在 1000 步 NeoRL simulator 中完成 development 控制变量实验和未使用 seeds 100–109 的最终评价。

最终结果显示：M100 由 GRU + CEM 取得稳定提升，M1000 与 M10000 由 Transformer-2L + MPPI 取得更大提升，三个系统对 BC 的 final win rate 均为 100%。与此同时，实验也揭示 one-step accuracy 不充分、prediction ranking 与 control ranking 不完全一致、弱模型可能被 optimizer 利用，以及更多数据不保证 downstream return 单调上升。这些观察直接引出真实工业部署所需的不确定性评估、安全约束、OOD detection、fallback controller 和持续监控。

表 7: Coverage of the assessment requirements.

Requirement	Evidence	Main result
Task 1: Industrial World Model	Figures 2 and 3 and table 2	统一比较 one-step 与 H5–H50 recursive error
Task 2: Strategy optimization	Figures 5 and 6	Planning 与 MB-PPO 均完成; KL 抑制明显失效
Task 3: NeoRL Simulator	Figure 8 and table 6	三个 final systems 均在 10 个未使用 seed 上胜过 BC
Expected Outcome 4	Sections 7 and 8	分析实验发现、工业用途与部署风险

参考文献

- [1] R.-J. Qin, X. Zhang, S. Gao, X.-H. Chen, Z. Li, W. Zhang, and Y. Yu. NeoRL: A Near Real-World Benchmark for Offline Reinforcement Learning. *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*, 2022.
- [2] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 2017.
- [3] C. Pinneri, S. Sawant, S. Blaes, J. Achterhold, J. Stueckler, M. Rolinek, and G. Martius. Sample-efficient Cross-Entropy Method for Real-time Planning. *Proceedings of Machine Learning Research*, 155:1049–1065, 2021.
- [4] G. Williams, A. Aldrich, and E. A. Theodorou. Model Predictive Path Integral Control: From Theory to Parallel Computation. *Journal of Guidance, Control, and Dynamics*, 40(2):344–357, 2017.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal Policy Optimization Algorithms. *arXiv:1707.06347*, 2017.