

面向工业过程控制的世界模型： 状态演化建模、策略优化与 NeoRL 仿真验证

2026 年 8 月 16 日

摘要

本文基于 NeoRL Industrial Benchmark 构建面向工业过程控制的世界模型 (World Model) 与策略优化流程。针对 100、1000 和 10000 条训练轨迹三种数据规模, 比较 MLP、GRU、LSTM、Transformer-2L 和 Transformer-4L 的状态预测能力, 并结合单步预测与多步递归预测评价模型; 随后使用冻结的世界模型比较 CEM、iCEM、MPPI 和 MB-PPO, 在 NeoRL 仿真环境中进行 1000 步长期控制验证。小规模数据下 GRU 的综合预测误差最低, 中、大规模数据下 Transformer-2L 更优。最终 M100 采用 GRU+CEM, M1000 和 M10000 采用 Transformer-2L+MPPI, 1000 步累计奖励分别为 $-274,181$ 、 $-220,129$ 和 $-223,876$, 相对行为克隆 (BC) 基础策略分别提高 14,229、68,282 和 64,535。所构建的世界模型能够支持后续策略优化, 并在当前基准中改善长期控制效果。

目录

1 项目概述	4
2 问题定义与数据	4
2.1 状态、动作与状态转移	4
2.2 奖励函数与评价指标	5
2.3 原始行为数据参考	5
3 世界模型设计	5
3.1 模型架构	5
3.2 预测评价与模型选择	6
4 世界模型实验结果	6
4.1 模型架构与数据规模	6
4.2 单步预测与多步递归误差	7
4.3 Transformer 深度消融	8
4.4 代表性长时域预测	9
5 基于世界模型的策略优化	9
5.1 基于模型的规划	9
5.2 规划长度选择	10
5.3 基于模型的强化学习	10
6 NeoRL 仿真验证	11
6.1 不同数据规模下的策略比较	11
6.2 世界模型对不同策略的影响	12
6.3 最终控制效果	13
7 实验观察与讨论	14
7.1 单步准确率不足以评价长期预测能力	14
7.2 预测精度与控制效果并不完全一致	15
7.3 世界模型误差可能被策略优化放大	15
7.4 数据增加不一定带来单调的控制收益	15
7.5 不同数据规模下的模型架构表现差异	15
8 工业应用与部署思考	15
8.1 潜在工业应用	15
8.2 实际部署中的风险与保障	15
9 进一步研究方向	16
10 总结	16

A	补充实验结果	16
A.1	完整世界模型预测结果	16
A.2	变量级预测误差	17
A.3	数据规模与训练设置	17

1 项目概述

工业过程通常具有长时滞、变量耦合以及直接试错成本高等特点。仅依靠历史轨迹训练策略，难以在执行前回答“某个控制动作将使设备状态如何演化”；直接在真实设备上反复搜索动作则可能带来能耗、磨损和安全风险。本项目从已有工业轨迹学习可递归预测未来状态的世界模型，再利用冻结模型进行动作序列规划或策略学习，最后在 NeoRL 仿真环境中验证长期控制效果。

整体技术路线见图 1。历史状态序列和动作首先用于训练世界模型；模型通过单步预测和多步递归预测评价后被冻结，分别支持基于模型的规划方法 CEM、iCEM、MPPI，以及基于模型的强化学习方法 MB-PPO。经过优化的策略最终在 NeoRL 仿真环境中执行，以 1000 步累计奖励衡量长期控制效果。




图 1: 项目整体技术路线。NeoRL 历史轨迹被整理为历史状态序列与连续动作，用于训练下一状态预测模型。世界模型经过单步与多步预测评价后被冻结，并分别服务于基于模型的规划和基于模型的强化学习；优化后的控制策略在 NeoRL 仿真环境中验证长期累计奖励。

本项目比较五类世界模型、三种规划方法和一种基于模型的强化学习方法。最终在 M100 上选择 GRU+CEM，在 M1000 与 M10000 上选择 Transformer-2L+MPPI。正文依次介绍状态与奖励定义、世界模型构建与评价、策略优化方法、仿真实验结果，以及这些结果对工业部署的启示。

2 问题定义与数据

2.1 状态、动作与状态转移

NeoRL Industrial Benchmark 中的观测为 180 维向量，可重排为 30 个历史帧，每帧包含 6 个物理变量：设定值 (setpoint)、速度 (velocity)、增益 (gain)、偏移 (shift)、疲劳度 (fatigue) 和能耗 (consumption)。动作 $a_t \in [-1, 1]^3$ 是三维连续控制量。令单帧为 $x_t \in \mathbb{R}^6$ ，历史窗口为 $x_{t-29:t}$ ，世界模型学习

$$(x_{t-29:t}, a_t) \mapsto \hat{x}_{t+1}. \quad (1)$$

预测下一帧后，将 $\hat{x}_{t+1}$ 放入历史窗口并移除最旧帧，从而构造下一次递归预测所需的 180 维状态。五类模型采用一致的输入输出形式： $[B, 30, 6]$ 的历史序列与 $[B, 3]$ 的动作映射到 $[B, 6]$ 的下一帧。

2.2 奖励函数与评价指标

NeoRL 的工业控制奖励为

$$r_{t+1} = - (3 \text{ fatigue}_{t+1} + \text{consumption}_{t+1}). \quad (2)$$

累计奖励越高，表示由疲劳度和能耗构成的综合控制代价越低。本文将一个 1000 步控制回合内的奖励求和，称为 1000 步累计奖励；后文简称累计奖励。仿真奖励只用于策略优化和最终控制评价，不参与世界模型的模型选择。

2.3 原始行为数据参考

原始行为数据参考值 (Original Behavior) 来自 NeoRL 数据集中的历史轨迹，这些轨迹由原始行为策略生成。本项目未获得可直接重新部署的原始行为策略权重，因此使用数据集中已有轨迹的累计奖励描述原始行为水平；BC 和世界模型优化策略则在 NeoRL 仿真环境中重新部署评价。两类结果的评价来源不同，原始行为数据参考值用于提供历史行为水平参照 [1]。

本文实际使用的三个正式训练集分别包含 100、1000 和 10000 条完整工业轨迹，后文记为 M100、M1000 和 M10000。每条轨迹包含 1000 个连续控制时间步，因此三个规模分别提供 100,000、1,000,000 和 10,000,000 个可用状态转移样本。这里的规模名称表示完整轨迹数量，而不是相互独立的单步样本数量。跨规模比较不使用原始训练轮数判断优劣，因为不同数据规模的一轮训练对应的样本数量不同；主要比较依据是统一验证得到的最终预测指标。

3 世界模型设计

3.1 模型架构

本文比较五类状态演化模型。MLP 将完整历史窗口展平后进行静态非线性映射；GRU 和 LSTM 通过递归隐状态提取时间依赖，其中 GRU 使用较简化的门控结构，LSTM 使用显式记忆单元；Transformer-2L 和 Transformer-4L 通过自注意力直接建模 30 帧之间的依赖 [3]。主要结构与参数量见表 1。

表 1: 世界模型架构。参数量不随数据规模改变。

模型架构	时间信息建模方式	主要配置	参数量
MLP	无显式时序递归	2×256 , dropout 0.1	114,438
GRU	门控递归状态	2 层, 隐状态 128, 动作分支 64	177,030
LSTM	带记忆单元的递归状态	2 层, 隐状态 128, 动作分支 64	227,462
Transformer-2L	自注意力历史编码	$d = 64$, 4 头, FFN 128, 2 层	91,142
Transformer-4L	自注意力历史编码	$d = 64$, 4 头, FFN 128, 4 层	158,086

同一数据规模内，不同模型使用相同的数据划分、归一化方式、训练预算、优化器和模型选择规则，仅改变模型架构。Transformer-2L 与 Transformer-4L 除编码层数外，其余结构与训练设置保

持一致，从而使深度消融具有明确的控制变量。跨数据规模不通过原始训练轮数比较优劣，因为每轮训练对应的数据量不同。

3.2 预测评价与模型选择

为保证不同模型架构和数据规模的预测误差可以直接比较，所有候选模型均在同一组验证轨迹上重新计算归一化均方根误差 (Normalized Root Mean Squared Error, NRMSE)，并采用统一的目标变量尺度进行归一化。设第 j 个目标变量的归一化尺度为 σ_j ，包含 N 个样本时，整体指标为

$$\text{NRMSE} = \sqrt{\frac{1}{6N} \sum_{i=1}^N \sum_{j=1}^6 \left(\frac{\hat{x}_{ij} - x_{ij}}{\sigma_j} \right)^2}. \quad (3)$$

NRMSE 越低表示预测误差越小。本文将上述统一数据、样本筛选规则和归一化尺度下的评价方式称为统一验证。

为评价连续预测中的误差传播，本文进一步进行多步递归预测。 H_k 表示从真实历史状态出发连续递归预测后，第 k 个预测时间步上的 NRMSE，并不是前 1 至 k 步预测误差的算术累加。递归过程中继续使用记录轨迹中的后续动作，但状态由模型逐步预测生成，不再用真实状态替换。例如， $H5$ 表示连续预测 5 个时间步后的误差， $H50$ 表示连续预测 50 个时间步后的误差；由于它们评价的是各自时间步上的预测偏差，单个变量的 $H50$ 不一定大于 $H20$ 。单步 NRMSE 遍历全部验证转移； $H1$ 使用相同的预测定义和归一化尺度，但只统计能够继续构造最长 50 步轨迹、并满足统一起点间隔的递归预测起点，因此两者数值接近但并非同一评价样本。变量级误差用于判断整体指标是否由少数物理变量主导。

在固定 M1000 GRU+CEM 设置下，规划长度消融中 $H=10$ 取得三个候选长度中的最高平均回报（见第 5.2）；后续规划实验统一采用 10 步预测长度。因此世界模型选择重点考察 $H5$ 、 $H10$ 和 $H20$ ，覆盖实际规划时间尺度及其邻近范围； $H50$ 进一步反映更长时间递归预测中的稳定性和误差传播。模型评价由此同时覆盖基础单步预测、与实际控制相匹配的短中期递归能力以及更长期的误差传播，而不是由某一个预测步长单独决定。

世界模型只根据统一验证的状态预测结果选择：

1. 找到该数据规模下最低的单步 NRMSE；
2. 保留单步 NRMSE 不超过最优值 1.10 倍的候选模型；
3. 在候选模型中最小化 $\text{mean}(H5, H10, H20)$ ；
4. 同时参考 $H50$ 观察更长时域下的递归稳定性。

该规则先排除单步预测明显不合格的模型，再比较短中期递归预测的稳定性。CEM、iCEM、MPPI、MB-PPO 的仿真奖励均不进入世界模型选择流程。

4 世界模型实验结果

4.1 模型架构与数据规模

正式比较包含 5 种架构与 3 个数据规模，共 15 组世界模型。图 2 以两个热图分别展示单步预测误差与 $H5$ 、 $H10$ 、 $H20$ 的平均递归预测误差；所有单元格均来自统一验证，边框表示各数据规模最终选定的模型。




图 2：模型架构与数据规模对预测误差的共同影响。 a，单步预测 NRMSE；b，H5、H10 和 H20 的平均 NRMSE。数值越低表示预测越准确，边框标出最终选定模型。单步预测排序与多步递归预测排序并不完全相同，不同数据规模下最合适的模型也存在差异。

M100 中，GRU 在单步误差合格的候选模型中取得最低短中期综合误差；M1000 与 M10000 则由 Transformer-2L 胜出。不同数据规模对应的最优架构并不相同，说明不同模型架构的相对表现会随数据规模发生变化。尤其是 M10000 中 MLP 并未因数据增多而自动获得更低误差，数据覆盖、训练预算和模型表达能力需要结合分析。

表 2：统一验证选出的世界模型，同时列出 H50 以展示更长时域的递归预测表现。

数据规模	模型架构	选定轮次	单步	H5	H10	H20	H50
M100	GRU	35	0.180	0.223	0.273	0.374	0.649
M1000	Transformer-2L	20	0.183	0.243	0.305	0.405	0.774
M10000	Transformer-2L	4	0.205	0.258	0.298	0.293	0.510

三个数据规模的模型均完成预设训练预算，并在架构内保存的候选 checkpoint 中按照统一验证协议选择参数。不同规模每轮包含的状态转移数相差一个至两个数量级，原始 epoch 数并不能直接代表相同训练工作量；三个最终世界模型的选定与最后一轮训练/验证损失见附录表 11，代表性 50 轮训练历史见图 9。

4.2 单步预测与多步递归误差

单步预测只评价在真实历史状态条件下预测下一帧；实际规划会把预测值重新输入模型，因此误差还会改变后续输入分布。图 3 展示五种世界模型在 1、5、10、20 和 50 步递归预测条件下的 NRMSE 变化。




图 3: M1000 上的多步递归预测误差。五种架构的短期误差较接近,但在 20 至 50 步明显分离; Transformer-2L 的 H5-H20 综合误差最低,而 Transformer-4L 的 H50 误差更低。

表 3 进一步比较每个数据规模下 H5/H10/H20 综合指标与 H50 的最优架构。M100 和 M1000 的两种排序并不一致, M10000 则同时由 Transformer-2L 取得最低误差。这说明世界模型的相对表现与关注的预测时间尺度有关。结合后续 10 步规划长度, 本文将 H5/H10/H20 作为主要递归选择指标, 以覆盖实际规划时间尺度及其邻近范围; H50 则补充反映更长时域下的递归稳定性。

表 3: 预测时间尺度敏感性。每列均在同一数据规模的五种架构中直接比较 NRMSE, 数值越低越优。

数据规模	H5/H10/H20 综合最优架构	H50 最优架构	是否一致
M100	GRU	LSTM	否
M1000	Transformer-2L	Transformer-4L	否
M10000	Transformer-2L	Transformer-2L	是

4.3 Transformer 深度消融

表 4: Transformer 深度消融。单元格为单步 NRMSE / H5、H10、H20 平均 NRMSE; 差值为 4L 减 2L, 负值表示 4L 更优。

数据规模	Transformer-2L	Transformer-4L	差值
M100	0.179 / 0.470	0.182 / 0.425	+0.003 / -0.044
M1000	0.183 / 0.318	0.183 / 0.338	+0.000 / +0.020
M10000	0.205 / 0.283	0.188 / 0.295	-0.017 / +0.012

M100 中，4L 改善了多步综合误差但单步略差；M1000 中，4L 的 H50 更低，但 H5-H20 综合误差反而更高；M10000 中，4L 单步更好，却在 H20 与综合指标上落后 2L。三个规模没有呈现随数据增加而稳定增强的深度收益，当前设置下继续增加层数缺少直接实验依据。

4.4 代表性长时域预测

不同物理变量的误差累积速度存在明显差异，完整变量级结果移至附录 A。图 4 保留速度、疲劳度和能耗三类代表性变量：速度反映动态控制状态，疲劳度和能耗则直接进入奖励函数。为避免只展示表现最好的样本，从候选验证轨迹中选择预测误差接近中位数的轨迹作为代表。




图 4：代表性 50 步递归预测轨迹。 a-c 分别展示速度、疲劳度和能耗的真实状态与模型预测。为避免只展示预测表现最好的样本，从候选验证轨迹中选择预测误差接近中位数的轨迹进行展示。短期趋势能够跟随真实状态，但不同变量的偏差以不同方式累积；总体结论仍以全部验证轨迹的 NRMSE 为准。

5 基于世界模型的策略优化

5.1 基于模型的规划

基于模型的规划在每个仿真步利用冻结世界模型评估候选动作序列，只执行序列中的第一个动作，再根据新观测重新规划。

- **CEM**: 每轮从当前动作分布中采样多条候选动作序列，通过冻结世界模型预测各序列的累计回报，再选取其中表现最好的若干序列作为精英样本，并根据这些精英样本更新下一轮动作分布

的均值和方差 [4]。

- **iCEM**: 在 CEM 基础上加入时间相关噪声、优良样本复用、上一时刻解的平移和采样规模递减等机制，以复用已有规划信息 [4]。
- **MPPI**: 依据预测代价为大量带噪动作序列分配权重，并以加权结果更新控制序列 [5]。与只保留少数优良样本的方法不同，MPPI 让更多样本按质量参与更新。

三种方法遵守 $[-1, 1]^3$ 的动作约束。规划期间世界模型保持冻结，控制回报不反向修改模型参数。

5.2 规划长度选择

规划长度消融固定 M1000 GRU 世界模型和 CEM 的其余设置：每轮采样 64 条候选动作序列，选取其中预测回报最高的 8 条作为精英样本，并进行两次分布更新，仅改变规划长度 H 。每个候选长度均在 5 个独立仿真初始条件下运行 1000 步。表 5 中的数值直接来自已有正式指标。

表 5: CEM 规划长度消融。固定 M1000 GRU 世界模型及其余规划参数，每个规划长度在 5 个独立仿真初始条件下运行 1000 步；累计奖励越高越好。

规划长度	1000 步累计奖励 (均值 $\pm$ 标准差)	中位数	相对表现
H=5	-280,284 $\pm$ 1,052	-280,283	低于 H=10 10,910
H=10	-269,374 $\pm$ 487	-269,072	最终采用
H=20	-272,618 $\pm$ 490	-272,625	低于 H=10 3,244

H=5 能够利用的未来状态范围较短；增大规划长度可以考虑更长期的累计收益，但更长的递归预测也会受到世界模型误差传播影响。在固定 M1000 GRU 世界模型和其余 CEM 参数的条件下，H=10 取得最高的平均累计奖励，相比 H=5 和 H=20 分别提高约 10,910 和 3,244。因此后续 CEM、iCEM 和 MPPI 均采用 10 步规划长度。

这一时间尺度也与 NeoRL 早期公开版本中的模型驱动策略设置一致，其中 MB-PPO 在学习到的转移模型中生成 10 步轨迹后进行 PPO 更新 [2]。本文的 MB-PPO 同样采用 10 步模型内想象轨迹。对于 CEM、iCEM 和 MPPI，10 步表示每次滚动规划的预测长度；对于 MB-PPO，10 步表示训练阶段在世界模型中生成的想象轨迹长度。

5.3 基于模型的强化学习

MB-PPO 在冻结世界模型中生成想象轨迹，再使用 PPO 的截断目标更新策略网络和价值网络，其设计结合 NeoRL 工业控制任务与 PPO 的策略优化方法 [1, 6]。与每一步都在线搜索的规划方法不同，MB-PPO 将模型中的优化结果压缩到一个可以直接推理的策略中。

KL 散度用于描述当前策略与行为克隆策略之间的分布差异。训练目标中的行为 KL 约束在提高模型内回报的同时限制策略过度偏离历史行为分布。图 5 固定世界模型、初始化、想象轨迹和 PPO 训练设置，仅改变是否加入行为 KL 约束。




图 5: MB-PPO 的行为 KL 约束消融。a, 5 次独立仿真的累计奖励；空心点表示每次独立仿真，实心点和误差条表示均值与标准差。b, 训练过程中当前策略与行为克隆策略之间的 KL 散度。为清楚展示跨度较大的 KL 散度变化，纵轴采用对数型尺度，并在接近零处保留线性区间。当前设置中，行为 KL 约束限制了策略偏离历史行为分布，并避免无约束训练出现严重性能退化。

6 NeoRL 仿真实验

NeoRL Industrial Benchmark 同时提供离线历史轨迹和可交互的工业仿真环境。本文的世界模型由历史轨迹训练；策略确定后，最终累计奖励由独立的 NeoRL IB 仿真环境产生。世界模型用于预测和策略优化，NeoRL simulator 则用于外部闭环评价。

6.1 不同数据规模下的策略比较

每个数据规模固定由统一预测评价选出的同一个世界模型，再比较 CEM、iCEM、MPPI 与 MB-PPO。所有策略在 5 组相同随机初始条件下独立重复仿真，采用相同的 1000 步回合与奖励定义。由此可以在相同世界模型和仿真条件下比较不同策略的控制效果。




图 6: 不同数据规模下的策略控制效果。 a–c 分别为 M100、M1000 和 M10000。三个面板使用相同纵轴范围；空心点表示每次独立仿真，实心点和误差条表示均值与标准差。M100 的 iCEM 平均累计奖励约为 -2.65×10^6 ，超出显示范围并在面板底部标注。CEM 在 M100 中最高，MPPI 在 M1000 和 M10000 中最高。

表 6: 不同数据规模下的策略累计奖励。 每种组合包含 5 次独立仿真，数值为均值 $\pm$ 标准差，越高越好。

数据规模	CEM	iCEM	MPPI	MB-PPO
M100	$-274,238 \pm 588$	$-2,646,910 \pm 4,581$	$-348,211 \pm 5,687$	$-281,009 \pm 131$
M1000	$-267,826 \pm 407$	$-334,597 \pm 4,503$	$-221,072 \pm 1,475$	$-285,326 \pm 158$
M10000	$-269,218 \pm 411$	$-321,264 \pm 36,310$	$-223,774 \pm 578$	$-285,217 \pm 283$

M100 上的 iCEM 和 MPPI 均明显落后，尤其 iCEM 出现一致的极低真实回报；在更充分的数据条件下，iCEM 恢复至正常数量级，表明其控制表现对世界模型误差和采样分布较为敏感。MPPI 在中、大规模数据条件下获得明显更高的累计奖励，而在小规模数据下效果下降，进一步说明规划策略的控制效果对世界模型的预测质量较为敏感。

6.2 世界模型对不同策略的影响

为进一步分析世界模型预测特征与实际控制效果之间的关系，本文在 M1000 上分别固定 MPPI 和 MB-PPO，仅改变世界模型架构进行两组控制变量比较。




图 7: 不同世界模型对 MPPI 与 MB-PPO 控制效果的影响。 a, 固定 MPPI, 仅改变世界模型; b, 固定 MB-PPO 训练设置, 仅改变世界模型。实验采用 M1000 数据规模, 每种组合包含 5 次独立仿真; 空心点表示单次结果, 实心点和误差条表示均值与标准差。两个面板分别采用适合各自结果范围的纵轴尺度, 比较重点为同一策略下不同世界模型的相对表现。统一预测评价最优的 Transformer-2L 并未在两种后续策略中都取得最高回报。

固定 MPPI 时, Transformer-4L 的平均累计奖励最高; 固定 MB-PPO 时, LSTM 的平均累计奖励最高。两组控制变量比较均未复现统一预测评价中的完整模型排序, 说明不同策略关注的模型误差特征可能有所不同, 相关关系在[第 7](#)中进一步讨论。

6.3 最终控制效果

模型、策略和参数确定后, 在 10 组未参与模型与策略选择的独立随机初始条件下进行最终仿真验证。最终系统为 M100 的 GRU+CEM, 以及 M1000、M10000 的 Transformer-2L+MPPI。[图 8](#)和[表 7](#)同时展示原始行为数据参考值、BC 基础策略与三个最终系统。

原始行为数据参考值统计 NeoRL 数据集已有轨迹的累计奖励; 由于本项目未获得可直接重新部署的原始行为策略权重, 该参考值与仿真策略采用不同评价来源。BC 和三个最终系统均在相同 1000 步回合定义下重新部署, 图表报告每次独立仿真以及均值和标准差, 从而分别呈现单次波动与整体水平。

最终 M100、M1000 和 M10000 系统相对 BC 的平均累计奖励分别提高 14,229、68,282 和 64,535。在 10 次独立仿真中, 三个最终系统每次都取得高于 BC 的累计奖励。经过统一预测评价和策略选择后, 基于世界模型的优化在当前 NeoRL 工业控制基准中改善了长期控制效果。




图 8: 最终 NeoRL 长期控制结果。左侧灰色分布表示原始行为（数据集历史轨迹），右侧表示在 NeoRL 仿真环境中重新部署的 BC 与三个最终系统。对仿真策略，每个空心点表示一次独立仿真，实心点和误差条表示均值与标准差。原始行为数据参考值来自数据集已有轨迹，与右侧仿真结果的评价来源不同。

表 7: 最终 NeoRL 控制结果。仿真方法在 10 组未参与模型和策略选择的独立随机初始条件下评价；原始行为来自数据集已有轨迹。

方法或系统	评价来源	1000 步累计奖励	相对 BC 变化
原始行为（数据集历史轨迹）	NeoRL 数据集历史轨迹	-282,885 ± 1,197	-
BC	NeoRL 仿真环境	-288,411 ± 267	0
M100: GRU + CEM	NeoRL 仿真环境	-274,181 ± 396	+14,229
M1000: Transformer-2L + MPPI	NeoRL 仿真环境	-220,129 ± 1,699	+68,282
M10000: Transformer-2L + MPPI	NeoRL 仿真环境	-223,876 ± 1,033	+64,535

7 实验观察与讨论

7.1 单步准确率不足以评价长期预测能力

单步预测的输入始终来自真实历史，而规划和想象轨迹会递归使用模型自己的预测。M1000 中多个模型的单步 NRMSE 很接近，但 H20 和 H50 差距明显；单步误差最低的模型也不一定具有最低的 H5-H20 综合误差。面向控制的世界模型需要联合评价单步预测和多步递归预测，单步损失无法完整描述长期预测能力。

7.2 预测精度与控制效果并不完全一致

M1000 控制变量实验中，统一预测评价选择 Transformer-2L；MPPI 在 Transformer-4L 上取得更高回报，MB-PPO 则在 LSTM 上表现更好。这一现象表明，通用预测误差与实际控制效果之间可能存在更复杂的关系，不同策略也可能对不同类型的模型误差具有不同敏感性。其具体影响机制，以及这一关系在其他模型、策略和数据规模下是否仍然存在，值得进一步研究。

7.3 世界模型误差可能被策略优化放大

M100 的结果显示，更复杂或采样更积极的优化器并不一定更可靠。规划器可能找到世界模型预测回报很高、但真实仿真表现较差的动作区域；当训练数据覆盖不足时，这类动作可能位于模型不可信的区域。基于模型的控制除了优化预测回报，还需要判断候选动作是否受到历史数据支持。

7.4 数据增加不一定带来单调的控制收益

从 M100 到 M1000，最终累计奖励明显提高；从 M1000 到 M10000 则没有继续单调提高，M1000+MPPI 的最终平均回报略高。这一非单调现象可能同时受到数据覆盖范围、模型架构、训练过程以及规划器对局部模型误差敏感性的影响，具体来源仍有待进一步通过控制变量实验区分。

7.5 不同数据规模下的模型架构表现差异

M100 中 GRU 取得更低的综合预测误差，递归结构在当前小数据设置中表现出一定优势；M1000 和 M10000 中轻量的 Transformer-2L 更优；Transformer-4L 没有稳定获得进一步收益。因此，模型架构的选择需要结合可用数据规模、多步预测表现以及后续控制任务综合考虑。

8 工业应用与部署思考

8.1 潜在工业应用

世界模型能够在不直接扰动设备的情况下回答“如果改变控制量，未来状态可能如何演化”。潜在用途包括工艺参数优化、能耗与设备疲劳联合控制、未来状态预测、假设性控制仿真、数字孪生、控制策略预验证、异常工况决策辅助，以及生产目标与设备状态的联合优化。对于复杂生产线，世界模型还可以作为操作员的决策支持工具，在执行动作前比较多种候选方案的预测后果。

8.2 实际部署中的风险与保障

真实工业数据通常比基准数据更复杂。传感器噪声、测量缺失、异常值和时间同步误差会直接污染 30 帧历史窗口；设备老化、维护、生产配方和工况变化会导致动力学漂移；停机、故障与极端负载往往在离线数据中很少出现，使模型在重要安全区域反而最不确定。部署前需要评估离线数据覆盖范围和分布外（out-of-distribution, OOD）工况，不能仅以训练数据数量替代覆盖性分析。

控制层还必须处理硬安全约束、执行器位置与变化速率约束、多目标权衡和操作员干预。疲劳度与能耗构成的奖励不能自动表达产品质量、产量、排放和设备安全的全部要求，关键约束应作为不可违反的控制边界，而不只是软奖励。故障检测、回退控制器和人工接管路径需要与学习策略同时设计。

本项目观察到的模型利用风险对工业部署尤为重要。实际系统需要限制优化器在世界模型高收益区域中的搜索范围，并结合模型不确定性、模型集合分歧、OOD 检测、可信动作区域、保守目标和安全过滤器。当不确定性超过阈值时，系统应回退到经过验证的 BC、传统控制器或人工操作。部署流程宜先经历离线回放、影子测试、受限工况试运行和逐级放权，并持续监测预测残差、动作分布、奖励组成和安全事件。

模型更新同样需要治理。持续监控应识别动力学漂移；模型更新或在线自适应需要保留版本、数据窗口、验证记录和回滚能力。关键工业场景还需要考虑网络与算力故障、推理超时、传感器冗余、审计日志和责任边界。世界模型的价值不是替代全部传统控制，而是在明确安全边界内增强预测、搜索和策略预验证能力。

9 进一步研究方向

世界模型方面，可进一步研究概率或集合动力学模型、不确定性感知模型、潜变量世界模型、状态空间模型与 Mamba、递归-注意力混合结构、面向决策的模型训练与选择，以及多次独立训练初始化下的鲁棒性。策略方面，可探索不确定性感知 MPC、保守规划、约束模型强化学习、更先进的基于模型或离线强化学习、其他轨迹优化方法、安全策略优化和受控在线自适应。这些方向主要面向模型不确定性、可信控制区域和工业动力学漂移问题。

10 总结

本文建立了从工业历史轨迹到世界模型、再到策略优化和 NeoRL 仿真验证的完整流程。实验比较了 MLP、GRU、LSTM、Transformer-2L 和 Transformer-4L，并在三个数据规模上统一评价单步与多步递归预测。综合预测结果选择 M100 的 GRU，以及 M1000、M10000 的 Transformer-2L 作为对应数据规模的冻结世界模型。

基于这些世界模型，本文完成 CEM、iCEM、MPPI 三种规划方法和 MB-PPO 的策略优化。最终 M100 使用 GRU+CEM，M1000 与 M10000 使用 Transformer-2L+MPPI；三者的 1000 步累计奖励相对 BC 分别提高 14,229、68,282 和 64,535。由此可以看出，当前世界模型能够为 NeoRL 工业控制基准中的长期策略优化提供有效支撑。

实验中还观察到多步误差累积、预测精度与控制效果不完全一致、世界模型误差可能被优化器放大，以及数据增加未必带来单调控制收益等现象。这些关系值得通过更充分的控制变量实验继续研究。面向真实工业应用，数据覆盖、不确定性估计、OOD 检测、安全约束、回退控制和持续监测与预测精度、控制回报同样重要，共同决定世界模型能否在可验证的安全边界内发挥预测与决策价值。

A 补充实验结果

A.1 完整世界模型预测结果

正文通过热图突出架构、数据规模与预测长度之间的主要关系，表 8 列出 15 组正式世界模型的完整数值，便于核查具体差异。

表 8: 五种架构在三个数据规模上的完整预测结果。所有数值均来自统一验证，平均值为 H5、H10 和 H20 的算术平均。架构内选定轮次表示该模型架构所有候选 checkpoint 中最终采用的参数位置。

数据规模	模型架构	架构内选定轮次	单步	H5	H10	H20	H50	H5-H20 平均
M100	MLP	35	0.190	0.282	0.380	0.464	0.825	0.376
M100	GRU	35	0.180	0.223	0.273	0.374	0.649	0.290
M100	LSTM	35	0.184	0.229	0.302	0.406	0.611	0.313
M100	Transformer-2L	35	0.179	0.314	0.456	0.638	0.899	0.470
M100	Transformer-4L	19	0.182	0.300	0.435	0.541	0.710	0.425
M1000	MLP	2	0.190	0.274	0.371	0.510	0.866	0.385
M1000	GRU	7	0.174	0.234	0.307	0.454	0.721	0.332
M1000	LSTM	13	0.176	0.272	0.381	0.555	0.975	0.403
M1000	Transformer-2L	20	0.183	0.243	0.305	0.405	0.774	0.318
M1000	Transformer-4L	40	0.183	0.245	0.319	0.450	0.658	0.338
M10000	MLP	1	0.219	0.412	0.597	0.738	0.857	0.582
M10000	GRU	1	0.188	0.293	0.423	0.669	1.201	0.461
M10000	LSTM	2	0.215	0.327	0.423	0.585	1.022	0.445
M10000	Transformer-2L	4	0.205	0.258	0.298	0.293	0.510	0.283
M10000	Transformer-4L	6	0.188	0.246	0.290	0.348	0.581	0.295

A.2 变量级预测误差

表 9 补充 M1000 最终选定世界模型在不同物理变量上的误差累积情况。

表 9: M1000 Transformer-2L 的变量级 NRMSE。不同物理变量的误差累积速度明显不同。

物理变量	单步	H20	H50
设定值	0.000	0.000	0.000
速度	0.029	0.310	0.704
增益	0.018	0.292	0.012
偏移	0.036	0.670	1.498
疲劳度	0.378	0.432	0.510
能耗	0.234	0.406	0.773

值得注意的是，增益变量在 H50 时的 NRMSE 为 0.012，明显低于 H20 时的 0.292。由于 H_k 表示第 k 个递归预测时刻的误差，而不是前 k 步误差的累加，因此变量级误差无需随预测步长单调增加。这也反映出不同物理变量在长时域递归预测中的误差演化具有不同特征。

A.3 数据规模与训练设置

表 10 汇总三个正式训练集的轨迹数、可用状态转移数与统一架构比较所采用的训练轮数。

表 10: 数据规模与统一架构比较的训练设置。每条轨迹均包含 1000 个连续控制时间步。

数据规模	训练轨迹数	每轨迹转移数	可用状态转移数	正式训练轮数
M100	100	1,000	100,000	50
M1000	1,000	1,000	1,000,000	50
M10000	10,000	1,000	10,000,000	10

不同数据规模的一个 epoch 包含完全不同的数据量，不能仅按轮数横向判断训练是否充分。M100、M1000 和 M10000 每轮分别暴露 100,000、1,000,000 和 10,000,000 个状态转移。各模型均按预设训练预算完整训练，并从保存的候选 checkpoint 中依据统一验证的单步与多步预测表现选择参数。部分模型在训练后期仍能继续降低训练误差，但验证性能没有同步改善，因此最终依据统一验证结果选择中间 checkpoint。

表 11: 三个最终世界模型的训练充分性与 checkpoint 位置。选定轮次由统一验证的单步与多步预测协议确定，训练/验证 MSE 用于观察优化过程。

数据规模	模型	总轮次	架构内选定轮次	选定训练 MSE	选定验证 MSE	最后训练 MSE	最后验证 MSE
M100	GRU	50	35	0.0343	0.0360	0.0333	0.0359
M1000	Transformer-2L	50	20	0.0288	0.0332	0.0252	0.0346
M10000	Transformer-2L	10	4	0.0185	0.0413	0.0145	0.0432




图 9: 代表性正式训练过程与候选 checkpoint 评价。a, M1000 Transformer-2L 的 50 轮训练历史。训练 MSE 随训练持续下降，而验证 MSE 在前期进入较低区间后未继续同步改善，并在后期呈现波动和部分回升。b, 统一验证中实际保存并评价的候选 checkpoint，虚线标出架构内最终采用的第 20 轮 checkpoint。继续降低训练误差没有带来稳定的验证收益，最终 checkpoint 仍依据前文统一验证中的单步和多步递归预测表现确定。

参考文献

- [1] R.-J. Qin, X. Zhang, S. Gao, X.-H. Chen, Z. Li, W. Zhang, and Y. Yu. NeoRL: A Near Real-World Benchmark for Offline Reinforcement Learning. *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022.
- [2] R. Qin, S. Gao, X. Zhang, Z. Xu, S. Huang, Z. Li, W. Zhang, and Y. Yu. NeoRL: A Near Real-World Benchmark for Offline Reinforcement Learning. *arXiv:2102.00714v2*, 2021.
- [3] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention Is All You Need. *Advances in Neural Information Processing Systems 30*, 2017.

- [4] C. Pinneri, S. Sawant, S. Blaes, J. Achterhold, J. Stueckler, M. Rolinek, and G. Martius. Sample-efficient Cross-Entropy Method for Real-time Planning. *Proceedings of Machine Learning Research*, 155:1049–1065, 2021.
- [5] G. Williams, A. Aldrich, and E. A. Theodorou. Model Predictive Path Integral Control: From Theory to Parallel Computation. *Journal of Guidance, Control, and Dynamics*, 40(2):344–357, 2017.
- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal Policy Optimization Algorithms. *arXiv:1707.06347*, 2017.