

# 面向工业过程控制的世界模型： 状态演化建模、策略优化与 NeoRL 仿真验证

2026 年 8 月 15 日

## 摘要

本文基于 NeoRL Industrial Benchmark 构建面向工业过程控制的世界模型 (World Model) 与策略优化流程。针对约 100、1000 和 10000 条训练轨迹三种数据规模, 比较 MLP、GRU、LSTM、Transformer-2L 和 Transformer-4L 的状态预测能力, 并结合单步预测与多步递归预测评价模型; 随后使用冻结的世界模型比较 CEM、iCEM、MPPI 和 MB-PPO, 在 NeoRL 仿真环境中进行 1000 步长期控制验证。实验结果显示, 小规模数据下 GRU 的综合预测误差最低, 中、大规模数据下 Transformer-2L 更优。最终 M100 采用 GRU+CEM, M1000 和 M10000 采用 Transformer-2L+MPPI, 1000 步累计奖励分别为  $-274,181$ 、 $-220,129$  和  $-223,876$ , 相对行为克隆 (BC) 基础策略分别提高 14,229、68,282 和 64,535。结果表明, 所构建的世界模型能够支持后续策略优化, 并在当前基准中改善长期控制效果。

# 目录

|                      |           |
|----------------------|-----------|
| <b>1 项目概述</b>        | <b>3</b>  |
| <b>2 问题定义与数据</b>     | <b>3</b>  |
| 2.1 状态、动作与状态转移       | 3         |
| 2.2 奖励函数与评价指标        | 4         |
| 2.3 原始行为数据参考         | 4         |
| <b>3 世界模型设计</b>      | <b>4</b>  |
| 3.1 模型架构             | 4         |
| 3.2 预测评价与模型选择        | 5         |
| <b>4 世界模型实验结果</b>    | <b>5</b>  |
| 4.1 模型架构与数据规模        | 5         |
| 4.2 单步预测与多步递归误差      | 6         |
| 4.3 Transformer 深度消融 | 7         |
| <b>5 基于世界模型的策略优化</b> | <b>8</b>  |
| 5.1 基于模型的规划          | 8         |
| 5.2 基于模型的强化学习        | 8         |
| <b>6 NeoRL 仿真验证</b>  | <b>9</b>  |
| 6.1 不同数据规模下的策略比较     | 9         |
| 6.2 世界模型对不同策略的影响     | 9         |
| 6.3 最终控制效果           | 10        |
| <b>7 实验观察与讨论</b>     | <b>11</b> |
| 7.1 单步准确率不足以评价长期预测能力 | 11        |
| 7.2 预测精度与控制效果并不完全一致  | 12        |
| 7.3 世界模型误差可能被策略优化放大  | 12        |
| 7.4 数据增加不一定带来单调的控制收益 | 12        |
| 7.5 模型架构与数据规模存在交互    | 12        |
| <b>8 工业应用与部署思考</b>   | <b>12</b> |
| 8.1 潜在工业应用           | 12        |
| 8.2 实际部署中的风险与保障      | 12        |
| <b>9 进一步研究方向</b>     | <b>13</b> |
| <b>10 总结</b>         | <b>13</b> |
| <b>A 变量级预测误差</b>     | <b>14</b> |

## 1 项目概述

工业过程通常具有长时滞、变量耦合以及直接试错成本高等特点。仅依靠历史轨迹训练策略，难以在执行前回答“某个控制动作将使设备状态如何演化”；直接在真实设备上反复搜索动作则可能带来能耗、磨损和安全风险。本项目从已有工业轨迹学习可递归预测未来状态的世界模型，再利用冻结模型进行动作序列规划或策略学习，最后在 NeoRL 仿真环境中验证长期控制效果。

整体技术路线见图 1。历史状态序列和动作首先用于训练世界模型；模型通过单步预测和多步递归预测评价后被冻结，分别支持基于模型的规划方法 CEM、iCEM、MPPI，以及基于模型的强化学习方法 MB-PPO。经过优化的策略最终在 NeoRL 仿真环境中执行，以 1000 步累计奖励衡量长期控制效果。




图 1: 项目整体技术路线。NeoRL 历史轨迹被整理为历史状态序列与连续动作，用于训练下一状态预测模型。世界模型经过单步与多步预测评价后被冻结，并分别服务于基于模型的规划和基于模型的强化学习；优化后的控制策略在 NeoRL 仿真环境中验证长期累计奖励。

本项目比较五类世界模型、三种规划方法和一种基于模型的强化学习方法。最终在 M100 上选择 GRU+CEM，在 M1000 与 M10000 上选择 Transformer-2L+MPPI。正文依次介绍状态与奖励定义、世界模型构建与评价、策略优化方法、仿真实验结果，以及这些结果对工业部署的启示。

## 2 问题定义与数据

### 2.1 状态、动作与状态转移

NeoRL Industrial Benchmark 中的观测为 180 维向量，可重排为 30 个历史帧，每帧包含 6 个物理变量：设定值 (setpoint)、速度 (velocity)、增益 (gain)、偏移 (shift)、疲劳度 (fatigue) 和能耗 (consumption)。动作  $a_t \in [-1, 1]^3$  是三维连续控制量。令单帧为  $x_t \in \mathbb{R}^6$ ，历史窗口为  $x_{t-29:t}$ ，世界模型学习

$$(x_{t-29:t}, a_t) \mapsto \hat{x}_{t+1}. \quad (1)$$

预测下一帧后，将  $\hat{x}_{t+1}$  放入历史窗口并移除最旧帧，从而构造下一次递归预测所需的 180 维状态。五类模型采用一致的输入输出形式： $[B, 30, 6]$  的历史序列与  $[B, 3]$  的动作映射到  $[B, 6]$  的下一帧。

## 2.2 奖励函数与评价指标

NeoRL 的工业控制奖励为

$$r_{t+1} = -(3 \text{ fatigue}_{t+1} + \text{consumption}_{t+1}). \quad (2)$$

因此，降低设备疲劳度和资源消耗会使奖励提高，即数值变得较少负。本文将一个 1000 步控制回合内的奖励求和，称为 1000 步累计奖励；后文简称累计奖励。仿真奖励只用于策略优化和最终控制评价，不参与世界模型的模型选择。

## 2.3 原始行为数据参考

原始行为数据参考值 (Original Behavior) 来自 NeoRL 数据集中的历史轨迹。NeoRL 数据集中的已有轨迹由原始行为策略生成。由于公开数据未提供可直接重新部署该采集策略的完整策略权重，本文统计数据集中已有轨迹的累计奖励，用于表示原始行为的大致水平；BC 和世界模型优化策略则在 NeoRL 仿真环境中重新部署评价。因此，原始行为数据参考值用于描述历史数据的行为水平，不与仿真策略进行严格的同条件配对统计 [1]。

三个数据规模 M100、M1000 与 M10000 分别提供不同数量级的历史轨迹。跨规模比较不使用原始训练轮数判断优劣，因为不同数据规模的一轮训练对应的样本数量不同；主要比较依据是统一验证得到的最终预测指标。

# 3 世界模型设计

## 3.1 模型架构

本文比较五类状态演化模型。MLP 将完整历史窗口展平后进行静态非线性映射；GRU 和 LSTM 通过递归隐状态提取时间依赖，其中 GRU 使用较简化的门控结构，LSTM 使用显式记忆单元；Transformer-2L 和 Transformer-4L 通过自注意力直接建模 30 帧之间的依赖 [2]。主要结构与参数量见表 1。

表 1: 世界模型架构。参数量不随数据规模改变。

| 模型架构           | 时间信息建模方式   | 主要配置                         | 参数量     |
|----------------|------------|------------------------------|---------|
| MLP            | 无显式时序递归    | $2 \times 256$ , dropout 0.1 | 114,438 |
| GRU            | 门控递归状态     | 2 层, 隐状态 128, 动作分支 64        | 177,030 |
| LSTM           | 带记忆单元的递归状态 | 2 层, 隐状态 128, 动作分支 64        | 227,462 |
| Transformer-2L | 自注意力历史编码   | $d = 64$ , 4 头, FFN 128, 2 层 | 91,142  |
| Transformer-4L | 自注意力历史编码   | $d = 64$ , 4 头, FFN 128, 4 层 | 158,086 |

同一数据规模内，不同模型使用相同的数据划分、归一化方式、训练预算、优化器和模型选择规则，仅改变模型架构。Transformer-2L 与 Transformer-4L 除编码层数外，其余结构与训练设置保持一致，从而使深度消融具有明确的控制变量。跨数据规模不通过原始训练轮数比较优劣，因为每轮训练对应的数据量不同。

### 3.2 预测评价与模型选择

为保证不同模型架构和数据规模的预测误差可以直接比较，所有候选模型均在同一组验证轨迹上重新计算 NRMSE，并采用相同的归一化尺度。本文将这一评价方式称为统一验证。评价包括单步 NRMSE，以及使用记录动作、但递归更新预测状态得到的 H1、H5、H10、H20 和 H50 NRMSE。变量级误差用于判断整体指标是否由少数物理变量主导。

世界模型只根据统一验证的状态预测结果选择：

1. 找到该数据规模下最低的单步 NRMSE；
2. 保留单步 NRMSE 不超过最优值 1.10 倍的候选模型；
3. 在候选模型中最小化  $\text{mean}(H5, H10, H20)$ ；
4. 将 H50 作为长期递归稳定性诊断，不单独用于选择模型。

该规则先排除单步预测明显不合格的模型，再比较短中期递归预测的稳定性。CEM、iCEM、MPPI、MB-PPO 的仿真奖励均不进入世界模型选择流程。

## 4 世界模型实验结果

### 4.1 模型架构与数据规模

正式比较包含 5 种架构与 3 个数据规模，共 15 组世界模型。图 2 以两个热图分别展示单步预测误差与 H5、H10、H20 的平均递归预测误差；所有单元格均来自统一验证，边框表示各数据规模最终选定的模型。




图 2：模型架构与数据规模对预测误差的共同影响。a，单步预测 NRMSE；b，H5、H10 和 H20 的平均 NRMSE。数值越低表示预测越准确，边框标出最终选定模型。单步预测排序与多步递归预测排序并不完全相同，不同数据规模下最合适的模型也存在差异。

M100 中，GRU 在单步误差合格的候选模型中取得最低短中期综合误差；M1000 与 M10000 则由 Transformer-2L 胜出。结果表明，模型架构与数据规模之间存在交互，不能据此宣称某种架构在

所有数据条件下都最优。尤其是 M10000 中 MLP 并未因为数据更多而自动获得更低误差，提示数据覆盖、训练预算和模型表达能力需要共同考虑。

表 2: 统一验证选出的世界模型。H50 仅用于长期稳定性诊断。

| 数据规模   | 模型架构           | 选定轮次 | 单步    | H5    | H10   | H20   | H50   |
|--------|----------------|------|-------|-------|-------|-------|-------|
| M100   | GRU            | 35   | 0.180 | 0.223 | 0.273 | 0.374 | 0.649 |
| M1000  | Transformer-2L | 20   | 0.183 | 0.243 | 0.305 | 0.405 | 0.774 |
| M10000 | Transformer-2L | 4    | 0.205 | 0.258 | 0.298 | 0.293 | 0.510 |

## 4.2 单步预测与多步递归误差

单步预测只评价在真实历史状态条件下预测下一帧；实际规划会把预测值重新输入模型，因此误差还会改变后续输入分布。图 3 固定 M1000，展示五种架构在五个真实评价步数上的结果。图中不包含插值或平滑，连接线仅用于辅助观察。





图 3: M1000 上的多步递归预测误差累积。标记点对应 1、5、10、20 和 50 步真实评价结果，连接线只作为视觉辅助。五种架构的短期误差较接近，但在 20 至 50 步明显分离；Transformer-2L 的 H5-H20 综合误差最低，而 Transformer-4L 的 H50 误差更低。

不同物理变量的误差累积速度存在明显差异，完整变量级结果移至附录 A。图 4 保留速度、疲劳度和能耗三类代表性变量：速度反映动态控制状态，疲劳度和能耗则直接进入奖励函数。为避免只展示表现最好的样本，从候选验证轨迹中选择预测误差接近中位数的轨迹作为代表。



**图 4: 代表性的 H50 多步递归预测轨迹。** a–c 分别展示速度、疲劳度和能耗的真实状态与模型预测。该轨迹的预测误差接近候选验证轨迹的中位数，不代表最好或最差情况。短期趋势能够跟随真实状态，但不同变量的偏差以不同方式累积；总体结论仍以全部验证轨迹的 NRMSE 为准。

4.3 Transformer 深度消融

**表 3:** Transformer 深度消融。单元格为单步 NRMSE / H5、H10、H20 平均 NRMSE；差值为 4L 减 2L，负值表示 4L 更优。

| 数据规模   | Transformer-2L | Transformer-4L | 差值              |
|--------|----------------|----------------|-----------------|
| M100   | 0.179 / 0.470  | 0.182 / 0.425  | +0.003 / -0.044 |
| M1000  | 0.183 / 0.318  | 0.183 / 0.338  | +0.000 / +0.020 |
| M10000 | 0.205 / 0.283  | 0.188 / 0.295  | -0.017 / +0.012 |

M100 中，4L 改善了多步综合误差但单步略差；M1000 中，4L 的 H50 更低，但 H5–H20 综合误差反而更高；M10000 中，4L 单步更好，却在 H20 与综合指标上落后 2L。现有结果没有显示层数增加会随数据规模扩大而稳定增强预测性能，因此不足以支持继续增加深度。



## 5 基于世界模型的策略优化

### 5.1 基于模型的规划

基于模型的规划在每个仿真步利用冻结世界模型评估候选动作序列，只执行序列中的第一个动作，再根据新观测重新规划。

- **CEM**: 从参数化动作分布中采样，保留高回报动作序列，并迭代更新采样分布的均值和方差。
- **iCEM**: 在 CEM 基础上加入时间相关噪声、优良样本复用、上一时刻解的平移和采样规模递减等机制，以复用已有规划信息 [3]。
- **MPPI**: 依据预测代价为大量带噪动作序列分配权重，并以加权结果更新控制序列 [4]。与只保留少数优良样本的方法不同，MPPI 让更多样本按质量参与更新。

三种方法的主要规划长度均为 10 步，并遵守  $[-1, 1]^3$  的动作约束。规划期间世界模型保持冻结，控制回报不反向修改模型参数。

### 5.2 基于模型的强化学习

MB-PPO 在冻结世界模型中生成想象轨迹，再使用 PPO 的截断目标更新策略网络和价值网络 [5]。与每一步都在线搜索的规划方法不同，MB-PPO 将模型中的优化结果压缩到一个可以直接推理的策略中。

KL 散度用于衡量当前策略与行为克隆策略之间的差异。训练目标中的行为 KL 约束要求策略在提高模型内回报的同时，不要无代价地偏离历史行为分布。图 5 固定世界模型、初始化、想象轨迹和 PPO 训练设置，仅改变是否加入行为 KL 约束。





图 5: MB-PPO 的行为 KL 约束消融。a, 5 次独立仿真的累计奖励；空心点表示每次独立仿真，实心点和误差条表示均值与标准差。b, 训练过程中当前策略与行为克隆策略之间的 KL 散度。在当前设置中，加入行为 KL 约束显著限制了策略偏离历史行为分布，并避免了无约束训练出现的严重性能退化；该结果不表示同一约束在所有任务上都必然有效。



## 6 NeoRL 仿真验证

### 6.1 不同数据规模下的策略比较

每个数据规模固定由统一预测评价选出的同一个世界模型，再比较 CEM、iCEM、MPPI 与 MB-PPO。所有策略在 5 组相同随机初始条件下独立重复仿真，采用相同的 1000 步回合与奖励定义。因此，图 6 和表 4 中的差异主要来自策略与固定世界模型之间的交互。



**图 6: 不同数据规模下的策略控制效果。** a–c 分别为 M100、M1000 和 M10000。三个面板使用相同纵轴范围；空心点表示每次独立仿真，实心点和误差条表示均值与标准差。M100 的 iCEM 平均累计奖励约为  $-2.65 \times 10^6$ ，超出显示范围并在面板底部标注。CEM 在 M100 中最高，MPPI 在 M1000 和 M10000 中最高。

**表 4: 不同数据规模下的策略累计奖励。** 每种组合包含 5 次独立仿真，数值为均值  $\pm$  标准差，越高越好。


| 数据规模   | CEM                | iCEM                   | MPPI                 | MB-PPO             |
|--------|--------------------|------------------------|----------------------|--------------------|
| M100   | -274,238 $\pm$ 588 | -2,646,910 $\pm$ 4,581 | -348,211 $\pm$ 5,687 | -281,009 $\pm$ 131 |
| M1000  | -267,826 $\pm$ 407 | -334,597 $\pm$ 4,503   | -221,072 $\pm$ 1,475 | -285,326 $\pm$ 158 |
| M10000 | -269,218 $\pm$ 411 | -321,264 $\pm$ 36,310  | -223,774 $\pm$ 578   | -285,217 $\pm$ 283 |

M100 上的 iCEM 和 MPPI 均明显落后，尤其 iCEM 出现一致的极低真实回报。由于相同算法已经在确定性优化测试中表现出基本优化能力，该结果提示弱世界模型与优化器之间可能发生模型利用现象，而不能据此断言 iCEM 普遍不适合工业过程。MPPI 在中、大规模数据下明显改善，而在小规模数据下表现下降，提示规划效果对世界模型质量较为敏感。

### 6.2 世界模型对不同策略的影响

M1000 上进一步完成两组控制变量实验：第一组固定 MPPI 配置，仅改变五种世界模型；第二组固定 MB-PPO 训练设置，仅改变世界模型。该实验用于研究统一预测评价中的模型排序与后续


控制效果是否完全一致，不用于反向修改世界模型的预测评价选择。



**图 7: 不同世界模型对 MPPI 与 MB-PPO 控制效果的影响。** a, 固定 MPPI, 仅改变世界模型; b, 固定 MB-PPO 训练设置, 仅改变世界模型。每种组合包含 5 次独立仿真, 空心点表示单次结果, 实心点和误差条表示均值与标准差。两个面板纵轴范围不同, 分别用于比较同一策略内部不同世界模型的相对表现, 不用于直接比较两个面板的视觉差距。统一预测评价最优的 Transformer-2L 并未在每一种后续策略中都取得最高回报, 这是当前实验观察而非普遍结论。

### 6.3 最终控制效果

模型、策略和参数确定后, 在 10 组未参与模型与策略选择的独立随机初始条件下进行最终仿真验证。最终系统为 M100 的 GRU+CEM, 以及 M1000、M10000 的 Transformer-2L+MPPI。图 8和表 5同时展示原始行为数据参考值、BC 基础策略与三个最终系统。



**图 8: 最终 NeoRL 长期控制结果。**左侧灰色分布表示原始行为（数据集历史轨迹），右侧表示在 NeoRL 仿真环境中重新部署的 BC 与三个最终系统。对仿真策略，每个空心点表示一次独立仿真，实心点和误差条表示均值与标准差。原始行为数据参考值来自数据集已有轨迹，与右侧仿真结果的评价来源不同。

**表 5: 最终 NeoRL 控制结果。**仿真方法在 10 组未参与模型和策略选择的独立随机初始条件下评价；原始行为来自数据集已有轨迹。

| 方法或系统                         | 评价来源          | 1000 步累计奖励       | 相对 BC 变化 |
|-------------------------------|---------------|------------------|----------|
| 原始行为（数据集历史轨迹）                 | NeoRL 数据集历史轨迹 | -282,885 ± 1,197 | —        |
| BC                            | NeoRL 仿真环境    | -288,411 ± 267   | 0        |
| M100: GRU + CEM               | NeoRL 仿真环境    | -274,181 ± 396   | +14,229  |
| M1000: Transformer-2L + MPPI  | NeoRL 仿真环境    | -220,129 ± 1,699 | +68,282  |
| M10000: Transformer-2L + MPPI | NeoRL 仿真环境    | -223,876 ± 1,033 | +64,535  |

最终 M100、M1000 和 M10000 系统相对 BC 的平均累计奖励分别提高 14,229、68,282 和 64,535。在 10 次独立仿真中，三个最终系统每次都取得高于 BC 的累计奖励。结果表明，经过统一预测评价和策略选择后，基于世界模型的优化能够在当前 NeoRL 工业控制基准中改善长期控制效果。

## 7 实验观察与讨论

### 7.1 单步准确率不足以评价长期预测能力

单步预测的输入始终来自真实历史，而规划和想象轨迹会递归使用模型自己的预测。M1000 中多个模型的单步 NRMSE 很接近，但 H20 和 H50 差距明显；单步误差最低的模型也不一定具有最低的 H5–H20 综合误差。该结果表明，面向控制的世界模型需要联合评价单步预测和多步递归预测，

不能只依据单步损失决定部署模型。

## 7.2 预测精度与控制效果并不完全一致

M1000 控制变量实验中，统一预测评价选择 Transformer-2L；MPPI 在 Transformer-4L 上取得更高的策略比较阶段回报，MB-PPO 则在 LSTM 上表现更好。这一现象提示，通用预测误差与下游控制效果可能并不完全一致，不同策略也可能对不同类型的模型误差具有不同敏感性。该结论仅是当前五种架构、两类策略和一个数据规模上的实验观察，不应上升为普遍规律，也不用于反向修改世界模型选择。

## 7.3 世界模型误差可能被策略优化放大

M100 的结果显示，更复杂或采样更积极的优化器并不一定更可靠。规划器可能找到世界模型预测回报很高、但真实仿真表现较差的动作区域；当训练数据覆盖不足时，这类动作可能位于模型不可信的区域。因此，基于模型的控制不仅要优化预测回报，还需要判断候选动作是否受到历史数据支持。

## 7.4 数据增加不一定带来单调的控制收益

从 M100 到 M1000，最终累计奖励明显提高；从 M1000 到 M10000 则没有继续单调提高，M1000+MPPI 的最终平均回报略高。该结果可能与数据覆盖范围、模型架构、训练预算结构以及规划器对局部误差的敏感性共同有关。现有实验只能说明更多数据没有自动转化为更高控制回报，不能把差异唯一归因于某一个因素。

## 7.5 模型架构与数据规模存在交互

M100 中 GRU 取得更低的综合预测误差，提示递归结构在当前小数据设置中具有一定优势；M1000 和 M10000 中轻量的 Transformer-2L 更优；Transformer-4L 没有稳定获得进一步收益。因此，架构选择需要结合数据规模、递归预测长度和后续策略共同考虑，而不应预设 Transformer 或循环网络必然获胜。

# 8 工业应用与部署思考

## 8.1 潜在工业应用

世界模型能够在不直接扰动设备的情况下回答“如果改变控制量，未来状态可能如何演化”。潜在用途包括工艺参数优化、能耗与设备疲劳联合控制、未来状态预测、假设性控制仿真、数字孪生、控制策略预验证、异常工况决策辅助，以及生产目标与设备状态的联合优化。对于复杂生产线，世界模型还可以作为操作员的决策支持工具，在执行动作前比较多种候选方案的预测后果。

## 8.2 实际部署中的风险与保障

真实工业数据通常比基准数据更复杂。传感器噪声、测量缺失、异常值和时间同步误差会直接污染 30 帧历史窗口；设备老化、维护、生产配方和工况变化会导致动力学漂移；停机、故障与极端

负载往往在离线数据中很少出现，使模型在重要安全区域反而最不确定。部署前需要评估离线数据覆盖范围和分布外（out-of-distribution, OOD）工况，不能仅以训练数据数量替代覆盖性分析。

控制层还必须处理硬安全约束、执行器位置与变化速率约束、多目标权衡和操作员干预。疲劳度与能耗构成的奖励不能自动表达产品质量、产量、排放和设备安全的全部要求，关键约束应作为不可违反的控制边界，而不只是软奖励。故障检测、回退控制器和人工接管路径需要与学习策略同时设计。

本项目观察到的模型利用风险对工业部署尤为重要。实际系统不能允许优化器无约束地搜索世界模型中的高收益区域，而应结合模型不确定性、模型集合分歧、OOD 检测、可信动作区域、保守目标和安全过滤器。当不确定性超过阈值时，系统应回退到经过验证的 BC、传统控制器或人工操作。部署流程宜先经历离线回放、影子测试、受限工况试运行和逐级放权，并持续监测预测残差、动作分布、奖励组成和安全事件。

模型更新同样需要治理。持续监控应识别动力学漂移；模型更新或在线自适应需要保留版本、数据窗口、验证记录和回滚能力。关键工业场景还需要考虑网络与算力故障、推理超时、传感器冗余、审计日志和责任边界。世界模型的价值不是替代全部传统控制，而是在明确安全边界内增强预测、搜索和策略预验证能力。

## 9 进一步研究方向

世界模型方面，可进一步研究概率或集合动力学模型、不确定性感知模型、潜变量世界模型、状态空间模型与 Mamba、递归-注意力混合结构、面向决策的模型训练与选择，以及多次独立训练初始化下的鲁棒性。策略方面，可探索不确定性感知 MPC、保守规划、约束模型强化学习、更先进的基于模型或离线强化学习、其他轨迹优化方法、安全策略优化和受控在线自适应。这些方向主要面向模型不确定性、可信控制区域和工业动力学漂移问题。

## 10 总结

本文建立了从工业历史轨迹到世界模型、再到策略优化和 NeoRL 仿真验证的完整流程。实验比较了 MLP、GRU、LSTM、Transformer-2L 和 Transformer-4L，并在三个数据规模上统一评价单步与多步递归预测。综合预测结果选择 M100 的 GRU，以及 M1000、M10000 的 Transformer-2L 作为对应数据规模的冻结世界模型。

基于这些世界模型，本文完成 CEM、iCEM、MPPI 三种规划方法和 MB-PPO 的策略优化。最终 M100 使用 GRU+CEM，M1000 与 M10000 使用 Transformer-2L+MPPI；三者的 1000 步累计奖励相对 BC 分别提高 14,229、68,282 和 64,535，表明世界模型能够在当前基准中有效支持长期策略优化。

实验还揭示了多步误差累积、预测精度与控制效果不完全一致、世界模型误差可能被优化器放大，以及数据增加不一定带来单调控制收益等问题。这些现象提示，真实工业应用除了追求预测精度和控制回报，还必须重视数据覆盖、不确定性估计、OOD 检测、安全约束、回退控制和持续监测，从而在可验证的安全边界内发挥世界模型的预测与决策价值。

## A 变量级预测误差

完整变量级结果用于补充说明不同物理变量的误差累积差异，不作为正文的主要模型排序依据。

**表 6:** M1000 Transformer-2L 的变量级 NRMSE。不同物理变量的误差累积速度明显不同。

| 物理变量 | 单步    | H20   | H50   |
|------|-------|-------|-------|
| 设定值  | 0.000 | 0.000 | 0.000 |
| 速度   | 0.029 | 0.310 | 0.704 |
| 增益   | 0.018 | 0.292 | 0.012 |
| 偏移   | 0.036 | 0.670 | 1.498 |
| 疲劳度  | 0.378 | 0.432 | 0.510 |
| 能耗   | 0.234 | 0.406 | 0.773 |

## 参考文献

- [1] R.-J. Qin, X. Zhang, S. Gao, X.-H. Chen, Z. Li, W. Zhang, and Y. Yu. NeoRL: A Near Real-World Benchmark for Offline Reinforcement Learning. *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*, 2022.
- [2] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 2017.
- [3] C. Pinneri, S. Sawant, S. Blaes, J. Achterhold, J. Stueckler, M. Rolinek, and G. Martius. Sample-efficient Cross-Entropy Method for Real-time Planning. *Proceedings of Machine Learning Research*, 155:1049–1065, 2021.
- [4] G. Williams, A. Aldrich, and E. A. Theodorou. Model Predictive Path Integral Control: From Theory to Parallel Computation. *Journal of Guidance, Control, and Dynamics*, 40(2):344–357, 2017.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal Policy Optimization Algorithms. *arXiv:1707.06347*, 2017.